As instruções destacadas em amarelo devem ser deletadas e substituídas pelo texto do manuscrito.

O artigo não deve ter qualquer identificação dos autores, estando essas restritas a capa.

Título em Português

Análise da pesquisa literary digest de 1936 por meio de ciência de dados e modelos de regressão.

Resumo

Objetivo: Analisar o erro das previsões eleitorais da pesquisa Literary Digest de 1936 por meio do tratamento, exploração e modelagem de dados históricos, buscando compreender as limitações relacionadas à representatividade dos dados e à capacidade preditiva dos modelos. **Métodos:** O estudo foi desenvolvido a partir das bases históricas das eleições de 1932 e da pesquisa de 1936, utilizando Python e as bibliotecas Pandas, NumPy, Matplotlib, Seaborn e Scikit-learn. Foram realizados procedimentos de carregamento, limpeza, padronização e organização dos dados, seguidos de análise exploratória e estatística para avaliar a distribuição dos votos, a participação dos estados e possíveis efeitos de vieses de amostragem e não-resposta. Posteriormente, os dados eleitorais de 1932 foram utilizados como variáveis de referência para modelos de Regressão Linear e Ridge, avaliados pelas métricas MAE, MSE, RMSE e R^2. **Resultados:** A Regressão Linear apresentou MAE de 12,40, MSE de 308,44, RMSE de 17,56 e R^2 de 0,13, enquanto o modelo Ridge apresentou MAE de 11,13, MSE de 222,64, RMSE de 14,92 e R^2 de 0,37. Os resultados demonstraram redução dos erros com a regularização Ridge, embora ambos os modelos apresentem limitações explicativas. **Conclusão:** Conclui-se que a representatividade e a qualidade dos dados são fundamentais para modelos preditivos, evidenciando que grandes volumes de dados não garantem previsões precisas quando existem vieses na coleta e limitações nas variáveis utilizadas.

Palavras-chave

Ciência de Dados; Análise de Dados; Regressão Linear; Aprendizado de Máquina; Viés de Amostragem.

Title in English

Analysis of the 1936 Literary Digest poll using data science and regression models.

Abstract

Objective: Analyze the prediction errors of the 1936 Literary Digest poll through the processing, exploration, and modeling of historical data, seeking to understand limitations related to data representativeness and the predictive capacity of the models. **Methods:** The study was conducted using historical datasets from the 1932 election and the 1936 poll, applying Python and the Pandas, NumPy, Matplotlib, Seaborn, and Scikit-learn libraries. Data loading, cleaning, standardization, and organization procedures were performed, followed by exploratory and statistical analyses to evaluate vote distributions, state participation, and possible effects of sampling and nonresponse biases. Subsequently, the 1932 election data were used as reference variables for Linear Regression and Ridge models, evaluated using MAE, MSE, RMSE, and R^2 metrics. **Results:** Linear Regression achieved an MAE of 12.40, MSE of 308.44, RMSE of 17.56, and R^2 of 0.13, while the Ridge model achieved an MAE of 11.13, MSE of 222.64, RMSE of 14.92, and R^2 of 0.37. The results demonstrated a reduction in prediction errors with Ridge regularization, although both models showed explanatory limitations.. **Conclusion:** It is concluded that data representativeness and quality are essential for predictive models, demonstrating that large volumes of data do not guarantee accurate predictions when data collection biases and limitations in the variables used are present.

Keywords

Data Science; Data Analysis; Linear Regression; Machine Learning; Sampling Bias.

Título en Español

Análisis de la investigación de Literary Digest de 1936 mediante ciencia de datos y modelos de regresión.

Resumen

Objetivo: Analizar los errores de predicción de la encuesta Literary Digest de 1936 mediante el procesamiento, exploración y modelado de datos históricos, buscando comprender las limitaciones relacionadas con la representatividad de los datos y la capacidad predictiva de los modelos. **Métodos:** El estudio se realizó a partir de conjuntos de datos históricos de las elecciones de 1932 y de la encuesta de 1936, utilizando Python y las bibliotecas Pandas, NumPy, Matplotlib, Seaborn y Scikit-learn. Se realizaron procedimientos de carga, limpieza, estandarización y organización de los datos, seguidos de análisis exploratorios y estadísticos para evaluar la distribución de los votos, la participación de los estados y los posibles efectos de los sesgos de muestreo y de no respuesta. Posteriormente, los datos electorales de 1932 se utilizaron como variables de referencia para modelos de Regresión Lineal y Ridge, evaluados mediante las métricas MAE, MSE, RMSE y R^2. **Resultados:** La Regresión Lineal presentó un MAE de 12,40, MSE de 308,44, RMSE de 17,56 y R^2 de 0,13, mientras que el modelo Ridge presentó un MAE de 11,13, MSE de 222,64, RMSE de 14,92 y R^2 de 0,37. Los resultados demostraron una reducción de los errores mediante la regularización Ridge, aunque ambos modelos presentaron limitaciones explicativas. **Conclusión:** Se concluye que la representatividad y la calidad de los datos son fundamentales para los modelos predictivos, evidenciando que grandes volúmenes de datos no garantizan predicciones precisas cuando existen sesgos en la recopilación y limitaciones en las variables utilizadas.

Palabras clave

Ciencia de Datos; Análisis de Datos; Regresión Lineal; Aprendizaje Automático; Sesgo de Muestreo.